

Forschungspraktikum

EKG Geschlechts Klassifikation

Felix Tempel
Studiengang Medizintechnik M. Sc.
Matrikelnummer: 22345525

Index Terms—Computer Science, Electrocardiography, ECG, Sex differences, Machine Learning, Classification, AI

1 EINLEITUNG

DAS Elektrokardiogramm (EKG) wurde 1901 von Willem Einthoven erfunden und hat sich über die Jahrzehnte zu einem der wichtigsten Untersuchungsmethoden in der Kardiologie etabliert. Gründe dafür sind unter anderem, dass die Untersuchung nicht-invasiv, schmerzfrei, einfach durchzuführen und jederzeit wiederholbar ist [1].

Aus dem EKG können verschiedene Physiologische und pathologische Vorgänge im Herzen abgeleitet werden. Dazu zählen z.B. die Herzfrequenz, Herzrhythmus und der Lagetyp des Herzens. Darüber hinaus können verschiedene Herzrhythmusstörungen mit hoher Zuverlässigkeit diagnostiziert werden [1].

Neben diesen Eigenschaften kann aber auch anhand eines EKG's auf das Geschlecht des Patienten zurückgeschlossen werden. Die Tatsache, dass sich das weibliche EKG von dem männlichen EKG unterscheidet, ist schon seit 1920 bekannt [2]. In den darauffolgenden Jahrzehnten wurden weitere Untersuchungen unternommen, die diese Erkenntnisse untermauerten. Es stellte sich heraus, dass je nach Geschlecht verschiedenen Segmenten im EKG unterschiedlich sind [2].

In diesem Forschungspraktikum soll anhand von normal-rhythmischen EKG Daten eine Klassifikation zwischen männlich und weiblich mittels verschiedener Machine-Learning Algorithmen realisiert werden.

2 METHODIK

Im ersten Schritt wurde eine Literaturrecherche unternommen um zu ermitteln, in welcher Hinsicht das männliche EKG sich von dem weiblichen unterscheidet. Hierbei wurde auf drei Arbeiten [2], [3], [4] zurückgegriffen, in denen die Autoren im wesentlichen fünf charakteristische Features benennen, in denen sich das EKG gut zwischen den Geschlechtern unterscheiden lässt.

Hierzu gehört unter anderem der *ST-Winkel*, *JT_{max}-Zeit*, *T-Winkel aufsteigend*, *T-Winkel absteigend* und die *T-Wellen Amplitude* (vgl. Abbildung 1).

2.1 Datenquellen und Entwicklungsumgebung

Für den Algorithmus wurde eine frei online verfügbare Datenbank verwendet: Die *China Physiological Signal Challenge 2018* [5].

Diese Datenbank enthält 6877 (weiblich: 3178; männlich: 3699) 12-Kanal-EKG Aufzeichnungen. Die Messungen sind zwischen sechs und sechzig Sekunden lang und wurden mit 500Hz aufgezeichnet.

Für den Algorithmus kamen nur die als *normal* gekennzeichneten EKG-Signale zum Einsatz, was in der Summe 900 Datensätze sind.

2.2 EKG preprocessing

Jedes *normale* EKG-Signal wurde für die nachfolgenden Feature Extraction vor

verarbeitet. Um das für ein EKG-Signal typische *Baselinewandering* zu entfernen wurde das Signal mit zwei *Median Filtern* gefiltert.

Im Anschluss konnte die *Noise* mit einem einfachen *Box Filter* minimiert werden. Durch diese Filtermethoden ist das EKG-Signal mit minimaler Veränderung ausreichend gefiltert, was eine genauere Feature Extraktion ermöglicht.

2.3 Feature Extraction

Um die o.g. Features zu berechnen wurde eine Routine entwickelt, die aus den *normalen* EKG-Daten eine Feature-Tabelle erstellt, die im nächsten Schritt oder zeitlich unabhängig dem Klassifizierung Algorithmus übergeben werden kann. In Abbildung 1 sieht man eine schematische Darstellung in der die jeweiligen Features im EKG Signal dargestellt sind.

Im ersten Schritt wird die Ableitung mit der




Fig. 1. Schematische Darstellung der verschiedenen Features [2]

höchsten T-Welle identifiziert, die später für ein Teil der Feature Berechnung herbeigezogen wird. Die T-Welle weist in Ableitung I und II sowie V3 bis V6 bei den meisten Menschen einen positiven Ausschlag auf [1], [2]. Für die Bestimmung wurde der Hochpunkt vor und nach dem ersten R-Peak bestimmt.

Für die Berechnung des J-Punktes, S-Welle und

R-Peak wurde die Ableitung V2 benutzt. Nach der oben beschriebenen Filterung konnten die Indices für diese Ableitung bestimmt werden.

Der R-Peak wurde mit dem *Pan-Tompkins Algorithmus* berechnet, der in dem Python Paket *biosppy* implementiert ist.

Die übrigen Features wurden mit Hilfe eines *moving windows* bestimmt. Da nur normale EKG Signale behandelt wurden, konnte man davon ausgehen, dass in den Bereichen auch die jeweiligen EKG Events vorliegen. Für den S-Peak wurde die Methode *scipy.signal.peak_finder* verwendet.

Der J-Punkte wurde über die Ableitung bestimmt. Ein Bereich nach dem S-Peak wurde festgelegt, der sich über 40 Samples erstreckt. In diesem Fenster wird das Minimum der Ableitung berechnet, wodurch der J-Punkt identifiziert werden kann.

Dieses Verfahren wurde für alle R-Peaks in einem Signal wiederholt, um später den Mittelwert in der jeweiligen Feature Berechnung bilden zu können.

Anschließend konnte anhand der Indices der verschiedenen Punkte die Features berechnet werden. Für *ST-Winkel* wurde ein Steigungsdreieck zwischen J-Punkt (+ 50 Samples) und der Baseline angelegt um über trigonometrische Funktionen den Winkel zu bestimmen.

Für den *T-Winkel aufsteigend* und *T-Winkel absteigend* ging man ähnlich vor - wählte für den Punkt im EKG Signal jeweils den steilsten *Gradienten*.

Bei der Berechnung der *JT_{max}*-Zeit konnte über die Differenz der schon bestimmten Punkte berechnet werden.

Die *T-Wellen Amplitude* wurde von der Baseline aus gemessen. Für die Berechnung wurde die Ableitung mit der höchsten *T-Wellen Amplitude* gewählt.

2.4 Training

Für die Klassifikation wurden eine Reihe von Algorithmen getestet, die im Anschluss abhängig ihrer Performance verglichen wurden. Die verwendeten Algorithmen waren u.a: *Support Vector Classification (linear und rbf kernel)*, *Gaussian Naive Bayes*, *Logistic Regression*,

Decision Tree classifier, Extra Trees Classifier, Multi-layer Perceptron classifier, AdaBoost classifier, k-nearest neighbors classifier, XGB classifier, Gradient Boosting classifier und Quadratic Discriminant Analysis. Diese stammen alle aus dem Python Paket *sklearn* [6].

Die Features wurden vor dem Training im Bereich von $[0, 1]$ *Min-Max* skaliert. Features, die über einer gesetzten Grenze liegen, wurden mit NaN Werten maskiert und anschließend durch einem *Simple Imputer* mit dem Mittelwert ersetzt.

Die EKG Daten konnten im nächsten Schritt in Trainings und Test Daten aufgeteilt werden. Das Verhältnis belief sich auf 30% Test- zu 70% Trainingsdaten.

2.5 Optimierung der Hyperparameter

Um eine möglichst genaue Klassifizierung zu erreichen wurden noch die Hyperparameter der Klassifikatoren automatisch angepasst.

Die besten fünf Klassifikatoren konnten man im Anschluss mit den berechneten Parametern auf das Test-Set anwenden. Die Performance der verschiedenen Klassifikatoren ist im nächsten Kapitel diskutiert.

3 ERGEBNISSE

In den folgenden Abbildungen ist die sog. *Receiver Operating Characteristics* (ROC) Kurve mit den *Area Under The Curve* (AUC) Werten angezeigt. Die verwendeten Hyperparameter sind in ebenfalls in der Legende abgebildet. Es wurden dabei die besten fünf Klassifikatoren, die im Mittel die beste Performanz besaßen in den Graph aufgenommen.

Es ist erkennbar, dass eine Klassifizierung über die gesamte Alterspanne keine genaue Vorhersage leisten kann (vgl. Abbildung 2), was sich auch mit der Aussage von [2] belegen lässt, die besagt, dass sich das EKG im Lebenslauf aufgrund verschiedener Hormonschwankungen und Umwelteinflüsse kontinuierlich verändert. Aus diesem Grund wurden die Features nach Altersklassen aufgeteilt und die jeweilige Genauigkeit bestimmt.

In Abbildung 3 ist die ROC Kurve von allen Patienten, die jünger als 30 Jahre alt sind aufgetragen. Mit dieser Aufteilung konnte der beste




Fig. 2. ROC für das komplette Dataset

Klassifikator *LogisticRegression* einen AUC Wert von 0.903 erreichen. In Abbildung 4 ist die

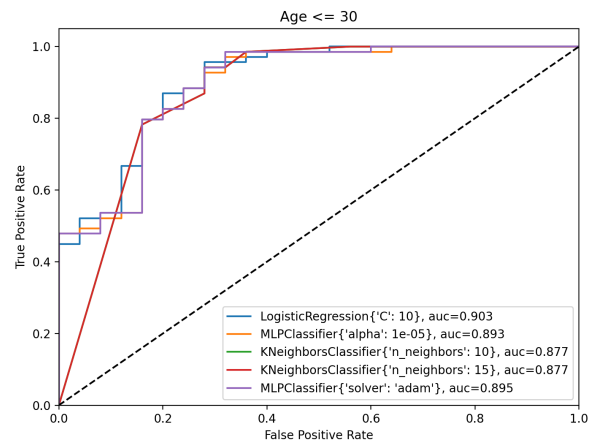


Fig. 3. ROC für Patienten jünger als 30 Jahre

ROC Kurve für alle Patienten, die älter als 30 Jahre alt sind dargestellt. In diesem Fall hat der *Support Vector Machine* Klassifikator einen AUC Wert von 0.87 erreichen können.

4 DISKUSSION

In diesem Forschungspraktikum konnte mit hoher einer Genauigkeit bestätigt werden, dass sich das männliche von dem weiblichem Geschlecht unterscheiden lässt.

Im weiteren Verlauf könnten noch die übrigen Features die [2] genannt hat extrahiert werden, um zu überprüfen ob die Performance weiter




Fig. 4. ROC für Patienten älter als 30 Jahre

verbessert werden kann.

Darüber hinaus könnte versucht werden, den Algorithmus in einer Weise zu optimieren, dass eine Klassifizierung auch bei EKG Daten funktioniert, die Arrhythmien aufweisen. Es bleibt zu überprüfen ob es sich nicht für diesen Fall anbietet, auf *unsupervised learning* bzw. *Deep Learning* zurückzugreifen, wie es auch [7] in ihrer Arbeit durchgeführt haben.

REFERENCES

- [1] M. Gertsch, G. Steinbeck, and B. Fässler, Das EKG: auf einen Blick und im Detail mit 54 Tabellen, 2. Aufl. Heidelberg: Springer Medizin, 2008.
- [2] H. Bidoggia et al., "Sex-dependent electrocardiographic pattern of cardiac repolarization," *American Heart Journal*, vol. 140, no. 3, pp. 430–436, Sep. 2000, doi: 10.1067/mhj.2000.108510.
- [3] B. Surawicz and S. R. Parikh, "Prevalence of male and female patterns of early ventricular repolarization in the normal ECG of males and females from childhood to old age," *Journal of the American College of Cardiology*, vol. 40, no. 10, p. 1870, Nov. 2002, doi: 10.1016/S0735-1097(02)02492-0.
- [4] H. Yang et al., "Maximal ascending and descending slopes of the T wave in men and women," *Journal of Electrocardiology*, vol. 30, no. 4, pp. 267–276, Oct. 1997, doi: 10.1016/S0022-0736(97)80038-6.
- [5] F. Liu et al., "An Open Access Database for Evaluating the Algorithms of Electrocardiogram Rhythm and Morphology Abnormality Detection," *j med imaging hlth inform*, vol. 8, no. 7, pp. 1368–1373, Sep. 2018, doi: 10.1166/jmihi.2018.2442.
- [6] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

- [7] Z. I. Attia et al., "Age and Sex Estimation Using Artificial Intelligence From Standard 12-Lead ECGs," *Circ: Arrhythmia and Electrophysiology*, vol. 12, no. 9, Sep. 2019, doi: 10.1161/CIRCEP.119.007284.